

회귀분석 I 학기말 과제 보고서

서울시 미세먼지 농도 결정요인에 대한 다중회귀분석

: 기상 요인, 해면기압 및 계절 효과를 중심으로

과목명	회귀분석 I(01)
담당교수	김규성 교수님
학과	통계학과
학번	2022580003
성명	김도원
제출일	2026 년 6 월 7 일

차례

1. 서론

1.1 연구 목적

1.2 문헌 연구

1.3 데이터 설명

1.4 분석 방법

1.5 결과 활용 및 기대 효과

2. 본론

2.1 분석 방법 소개

2.2 데이터 분석 및 결과 설명

2.3 분석의 타당성 설명

3. 결론

3.1 분석 결과 요약

3.2 분석의 장점 및 한계점

3.3 추가 연구사항 제안

참고문헌

부록. SAS 프로그램 코드 및 주요 결과표

1. 서론

1.1 연구 목적

본 보고서의 목적은 2025 년 서울시 일별 미세먼지 PM10 농도와 기상 요인 사이의 관계를 다중선형회귀모형을 이용하여 분석하는 것이다. 미세먼지는 사람의 건강과 생활환경에 직접적인 영향을 주는 대표적인 대기오염 지표이며, 같은 도시 안에서도 날짜와 기상 조건에 따라 농도가 크게 달라진다. 따라서 일별 관측자료를 바탕으로 PM10 농도와 평균기온, 평균습도, 평균풍속, 일강수량, 해면기압 등 기상 변수 사이의 관계를 확인하는 것은 환경자료의 변동 구조를 이해하는 데 의미가 있다.

본 연구는 특정 시점의 미세먼지 농도를 예측하기 위한 시계열 예측모형을 구축하는 것이 아니라, 하루 단위로 관측된 기상 요인들이 같은 날짜의 PM10 농도와 어떤 선형적 관련성을 갖는지를 확인하는 데 초점을 둔다. 이를 통해 PM10 농도가 단순히 시간에 따라 변동하는 값이 아니라, 기온, 습도, 풍속, 강수량, 해면기압 등 여러 기상 조건과 함께 변화하는 환경 지표임을 통계적으로 살펴보고자 한다.

또한 본 보고서는 실제 공공데이터를 수집·정리하여 다중회귀분석의 기본 절차를 적용해 보는 데 의의가 있다. 분석 결과를 통해 서울시 PM10 농도 변동에 관련된 주요 기상 요인을 파악하고, 향후 황사, 교통량, 배출원 정보, 전날 대기질 상태 등을 포함한 확장 연구의 기초자료를 마련하고자 한다.

1.2 문헌 연구

미세먼지 농도는 대기 중 입자상 물질의 농도를 나타내는 대기오염 지표로, 인체 건강과 생활환경에 영향을 미치는 중요한 환경 변수이다. 선행연구인 「미세먼지 농도 예측을 위한 머신러닝 기법의 정확도 분석」에서는 미세먼지 중 PM2.5가 입자의 크기가 작아 호흡기 및 심혈관 질환과 관련될 수 있으며, PM10 역시 호흡기 문제와 가시거리 감소에 영향을 줄 수 있다고 설명하였다. 따라서 미세먼지 농도의 변동 요인을 분석하고 예측하는 연구는 대기환경 분야에서 중요한 연구 주제로 다루어지고 있다.

선행연구에서는 미세먼지 농도 예측을 위해 PM10 과 PM2.5 를 종속변수로 두고, 대기오염물질 자료, 기상자료, 에어로솔 관련 자료를 설명변수 후보로 활용하였다. 해당 연구에서는 대기오염물질 관련 설명변수로 SO₂ , NO₂ , O₃ , CO, PM10, PM2.5 를 사용하였고, 기상 관련 설명변수로는 기온, 풍속, 풍향, 상대습도, 대기압, 가시거리, 이슬점 등을 포함하였다. 또한 다중선형회귀모형, Support Vector Machine, Random Forest, Deep Neural Network 를 비교하여 미세먼지 농도 예측 성능을 평가하였다. 이 연구는 미세먼지 농도가 단일 기상요인만으로

결정되는 것이 아니라, 대기오염물질과 다양한 기상조건이 함께 작용하여 변동한다는 점을 보여준다.

특히 해당 연구에서 다중선형회귀모형은 종속변수에 영향을 미치는 여러 독립변수의 기여도가 선형적으로 결합된다고 가정하는 방법으로 설명된다. 이는 본 보고서에서 사용하는 다중선형회귀모형과 직접적으로 연결된다. 다만 선행연구는 머신러닝 기법을 포함하여 예측 정확도 비교에 초점을 두었고, 본 보고서는 다중선형회귀모형을 이용해 2025년 서울시 일별 PM10 농도와 기상요인의 선형관계를 해석하는 데 초점을 둔다.

1.3 데이터 설명

분석 대상은 2025년 1월 1일부터 2025년 12월 31일까지 서울시에서 관측된 일별 자료 365개이다. 종속변수는 서울시 일평균 미세먼지 PM10 농도이며, 설명변수는 평균기온, 평균습도, 평균풍속, 일강수량, 일평균 해면기압이다.

PM10 자료는 서울특별시 대기환경정보의 「서울시 대기질 일별 통계」에서 수집하였다. 이 자료는 날짜별 서울시 평균 PM10 농도를 제공하므로, 일별 기상자료와 날짜 기준으로 결합하여 회귀분석을 수행하기에 적절하다. 기상자료는 기상청 기상자료개방포털에서 제공하는 서울(108) 지점의 일별 평균기온, 평균습도, 평균풍속, 일강수량 자료를 사용하였다. 강수량 자료에서 빈칸으로 표시된 값은 비가 오지 않은 날로 판단하여 0으로 대체하였다.

해면기압 자료는 기상청 종관기상관측(ASOS) 시간자료에서 서울(108) 지점의 2025년 1월 1일 00시부터 2025년 12월 31일 23시까지의 시간별 자료를 수집하였다. 본 연구의 관측 단위가 일별 자료이므로, 날짜별 24개 관측값의 산술평균을 계산하여 일평균 해면기압으로 변환하였다. 특정 시간의 기압만 사용하는 경우 해당 시간대의 일시적인 변화가 반영될 수 있으므로, 하루 평균값을 사용하는 것이 일별 회귀분석 자료의 관측 단위를 맞추는 데 더 적절하다고 판단하였다.

계절의 평균적 차이를 고려하기 위해 봄, 여름, 가을에 해당하는 0-1형 설명변수를 생성하였다. 겨울은 기준범주로 두었기 때문에 별도의 겨울 변수는 포함하지 않았다. 또한 토요일과 일요일은 1, 평일은 0의 값을 갖는 주말 여부 변수를 생성하였다. 이는 평일과 주말의 교통량 및 활동량 차이가 PM10 농도와 관련될 수 있다고 보았기 때문이다. 평일이 주말에 비해 교통량이 약 14%(주중 약 9,835 천 대/일, 주말 약 8,630 천 대/일) 증가하여 교통량 증가에 의한 미세먼지 농도 변화효과를 고려하였다. 내연기관 차량에서 배출되는

질소산화물(NO_x), 황산화물(SO_x) 등은 대기 중에서 화학반응을 일으켜 미세먼지를 생성하기 때문이다.

그림 1. 2025 년 요일별 교통량.




표 1. 분석에 사용한 변수 설명

변수명	내용	단위	비고
date	관측일자	-	2025 년 1 월 1 일~12 월 31 일
pm10	일평균 미세먼지 PM10 농도	μg/m ³	종속변수
log_pm10	PM10 의 자연로그 변환값	-	대안 종속변수
temp_avg	일평균 기온	℃	설명변수
hum_avg	일평균 상대습도	%rh	설명변수
wind_avg	일평균 풍속	m/s	설명변수
rain	일강수량	mm	결측값은 0 으로 처리
pressure_avg	일평균 해면기압	hPa	시간별 자료의 일평균
spring, summer, fall	계절 여부를 나타내는 0-1 형 변수	-	겨울 기준범주
weekend	주말 여부를 나타내는 0-1 형 변수	-	평일 기준범주

1.4 분석 방법

본 연구에서는 먼저 PM10 원자료를 종속변수로 하는 다중회귀모형을 적합하였다. 기본모형은 평균기온, 평균습도, 평균풍속, 일강수량만을 포함하였으며, 이후 해면기압을

추가한 모형과 계절 및 주말 정보를 추가한 확장모형을 비교하였다. 이를 통해 기상요인의 추가가 모형 설명력에 어느 정도 기여하는지 확인하였다.

두 번째로 PM10 농도의 분포 특성을 고려하여 $\log(\text{PM10})$ 을 종속변수로 하는 모형을 적합하였다. PM10 원자료는 오른쪽 꼬리가 긴 분포를 보였으며, 이는 원자료 모형의 잔차 정규성에 영향을 줄 수 있다. 자연로그 변환은 양수인 농도 자료의 비대칭성을 완화하고, 회귀계수 해석을 비율적 변화의 관점으로 전환할 수 있는 장점이 있다.

모형 평가는 R-Square와 Adjusted R-Square, F 검정, 개별 회귀계수의 t 검정, VIF, 잔차의 정규성 검토, 잔차 대 예측값 산점도, 스튜던트화 잔차, Cook의 거리 등을 이용하였다. 특히 최종모형 선택에서는 단순히 R-Square가 높은지뿐만 아니라 잔차분석 결과가 회귀모형의 기본 가정에 얼마나 부합하는지도 함께 고려하였다.

1.5 결과 활용 및 기대 효과

본 분석은 서울시 PM10 농도가 단순히 배출량만으로 설명되는 것이 아니라, 기온, 습도, 풍속, 강수량, 해면기압과 같은 기상 조건과도 관련된다는 점을 계량적으로 보여준다. 이러한 결과는 고농도 미세먼지 발생일의 환경 조건을 해석하거나, 기상 조건 변화에 따른 대기질 변화 가능성을 이해하는 기초자료로 활용될 수 있다.

실제 공공데이터를 수집하고 병합하여 분석했다는 점에서 데이터 품질과 분석 절차의 실용성을 함께 확인할 수 있다.

2. 본론

2.1 분석 방법 소개

다중선형회귀모형은 하나의 반응변수를 여러 개의 설명변수로 설명하는 모형이다. 본 연구의 기본 회귀식은 PM10 농도 또는 $\log(\text{PM10})$ 을 반응변수로 두고, 기상 요인과 계절 정보를 설명변수로 포함하는 형태이다. 기본적인 모형은 다음과 같이 표현할 수 있다.

원자료 모형은 PM10 자체를 종속변수로 사용하므로 회귀계수를 직관적으로 해석할 수 있다. 예를 들어 평균풍속의 회귀계수가 음수이면 다른 조건이 같을 때 풍속이 증가할수록 PM10 농도가 낮아지는 경향을 의미한다. 반면 $\log(\text{PM10})$ 모형은 종속변수를 로그변환하기 때문에 계수는 PM10의 상대적 변화 또는 비율적 변화의 관점에서 해석하는 것이 더 적절하다.

본 연구에서는 총 여섯 개의 회귀모형을 비교하였다. Model 1과 Model 4는 기상요인만 포함한 기본모형이며, Model 2와 Model 5는 해면기압을 추가한 모형이다. Model 3과 Model 6은 해면기압과 계절 및 주말 정보를 함께 포함한 확장모형이다. 이 중 Model 1~3은 PM10 원자료를 종속변수로 사용하고, Model 4~6은 $\log(\text{PM10})$ 을 종속변수로 사용하였다.

표 2. 적합한 회귀모형의 구성

모형	종속변수	설명변수	비고
Model 1	PM10	temp_avg, hum_avg, wind_avg, rain	기상요인 기본모형
Model 2	PM10	temp_avg, hum_avg, wind_avg, rain, pressure_avg	해면기압 추가
Model 3	PM10	temp_avg, hum_avg, wind_avg, rain, pressure_avg, spring, summer, fall, weekend	확장모형
Model 4	$\log(\text{PM10})$	temp_avg, hum_avg, wind_avg, rain	로그변환 기본모형
Model 5	$\log(\text{PM10})$	temp_avg, hum_avg, wind_avg, rain, pressure_avg	로그변환 + 해면기압
Model 6	$\log(\text{PM10})$	temp_avg, hum_avg, wind_avg, rain, pressure_avg, spring, summer, fall, weekend	최종 후보모형

2.2 데이터 분석 및 결과 설명

2.2.1 기초통계량과 분포

분석자료는 총 365개 관측값으로 구성되어 있다. PM10의 평균은 $31.82 \mu\text{g}/\text{m}^3$, 표준편차는 $18.73 \mu\text{g}/\text{m}^3$ 이며 최솟값은 $4 \mu\text{g}/\text{m}^3$, 최댓값은 $145 \mu\text{g}/\text{m}^3$ 로 나타났다. 평균에 비해 최댓값이 상당히 크므로 PM10 원자료는 오른쪽 꼬리가 긴 분포를 가질 가능성이 있다.

기상 변수의 경우 평균기온은 14.15°C , 평균습도는 65.85%rh, 평균풍속은 2.33m/s, 일강수량은 평균 4.34mm로 나타났다. 해면기압은 평균 1015.23hPa, 표준편차 8.61hPa, 최솟값

994.55hPa, 최댓값 1031.79hPa 로 나타났다. 계절 변수의 평균은 해당 계절에 속하는 관측비율을 의미하며, 봄과 여름은 각각 약 25.2%, 가을은 약 24.9%, 주말은 약 28.5%를 차지하였다.

표 3. 주요 변수의 기초통계량

기초통계량								
MEANS 프로시저								
변수	N	평균	표준편차	최솟값	제1 사분위수	중위수	제3 사분위수	최댓값
pm10	365	31.8246575	18.7313848	4.0000000	19.0000000	28.0000000	40.0000000	145.0000000
log_pm10	365	3.2965400	0.5932110	1.3862944	2.9444390	3.3322045	3.6888795	4.9767337
temp_avg	365	14.1504110	10.9411503	-9.7000000	4.4000000	14.7000000	23.7000000	32.8000000
hum_avg	365	65.8545205	13.8402706	29.4000000	55.1000000	66.8000000	75.5000000	98.1000000
wind_avg	365	2.3326027	0.6371339	1.3000000	1.9000000	2.2000000	2.7000000	6.3000000
rain	365	4.3353425	13.2592342	0	0	0	0.6000000	126.7000000
pressure_avg	365	1015.23	8.6058081	994.5500000	1008.68	1014.64	1022.47	1031.79
spring	365	0.2520548	0.4347886	0	0	0	1.0000000	1.0000000
summer	365	0.2520548	0.4347886	0	0	0	1.0000000	1.0000000
fall	365	0.2493151	0.4332104	0	0	0	0	1.0000000
weekend	365	0.2849315	0.4520014	0	0	0	1.0000000	1.0000000

그림 2. 2025 년 서울시 일별 PM10 농도 시계열




그림 2 는 2025 년 서울시 일별 PM10 농도의 변동을 보여준다. 특정 시점에 고농도 관측값이 나타나며, 일부 날짜의 극단적인 값은 회귀분석에서 이상치 또는 영향점으로 확인될 수 있다. 이러한 특성 때문에 단순 평균만으로 PM10 의 변동을 설명하기 어렵고, 기상 요인과 잔차 진단을 함께 고려할 필요가 있다.

그림 3. PM10 원자료 분포와 log(PM10) 분포




그림 3을 보면 PM10 원자료는 오른쪽 꼬리가 상대적으로 긴 반면, 로그변환 이후에는 분포가 더 대칭적인 형태에 가까워진다. 이 결과는 단순히 설명력을 높이기 위해서가 아니라 회귀모형의 잔차 정규성 측면에서 로그변환 모형을 검토할 필요가 있음을 보여준다.

2.2.2 상관분석 결과

상관분석 결과, PM10 원자료는 평균기온, 평균습도, 강수량과 음의 상관관계를 보였다. PM10과 평균기온의 상관계수는 -0.2762, 평균습도와의 상관계수는 -0.2586, 강수량과의 상관계수는 -0.2735로 나타났다. 평균풍속과 PM10의 상관계수는 -0.1026으로 상대적으로 약하지만, 유의확률은 약 0.0501로 경계적인 수준이었다.

log(PM10)은 기상 변수들과 더 뚜렷한 음의 상관관계를 보였다. 특히 log(PM10)과 강수량의 상관계수는 -0.3918, 평균습도와의 상관계수는 -0.3843, 평균기온과의 상관계수는 -0.3222로 나타났다. 해면기압은 PM10 원자료와의 상관계수는 0.0869로 약하지만, log(PM10)과는 0.1396으로 유의한 양의 상관관계를 보였다.

다만 상관분석은 두 변수 사이의 단순한 선형관계만을 보여주므로 다른 변수를 통제한 효과를 해석하기에는 한계가 있다. 예를 들어 해면기압은 평균기온과 강한 음의 상관관계를 보였기 때문에, 단순상관과 다중회귀에서의 회귀계수 방향이 다르게 나타날 수 있다. 따라서 최종 해석은 다중회귀모형의 결과를 기준으로 하였다.

표 4. PM10 및 log(PM10)과 주요 변수의 상관관계

변수	PM10 상관계수	p-value	log(PM10) 상관계수	p-value
temp_avg	-0.2762	<.0001	-0.3222	<.0001
hum_avg	-0.2586	<.0001	-0.3843	<.0001
wind_avg	-0.1026	0.0501	-0.1477	0.0047
rain	-0.2735	<.0001	-0.3918	<.0001
pressure_avg	0.0869	0.0976	0.1396	0.0076
spring	0.3397	<.0001	0.3291	<.0001
summer	-0.2594	<.0001	-0.2282	<.0001
fall	-0.2296	<.0001	-0.3045	<.0001
weekend	-0.0544	0.2996	-0.0421	0.4227

표 5. 모든 변수사이의 상관관계

피어슨 상관 계수, N = 365 HO: Rho=0 가정하에서 Prob > r											
	pm10	log_pm10	temp_avg	hum_avg	wind_avg	rain	pressure_avg	spring	summer	fall	weekend
pm10	1.00000	0.91303 <.0001	-0.27619 <.0001	-0.25857 <.0001	-0.10262 0.0501	-0.27346 <.0001	0.08685 0.0976	0.33973 <.0001	-0.25936 <.0001	-0.22956 <.0001	-0.05444 0.2996
log_pm10	0.91303 <.0001	1.00000	-0.32217 <.0001	-0.38434 <.0001	-0.14774 0.0047	-0.39175 <.0001	0.13959 0.0076	0.32905 <.0001	-0.22821 <.0001	-0.30452 <.0001	-0.04209 0.4227
temp_avg	-0.27619 <.0001	-0.32217 <.0001	1.00000	0.42787 <.0001	-0.19560 0.0002	0.19469 0.0002	-0.75544 <.0001	-0.05818 0.2676	0.68548 <.0001	0.11315 0.0307	0.02231 0.6710
hum_avg	-0.25857 <.0001	-0.38434 <.0001	0.42787 <.0001	1.00000	-0.13159 0.0119	0.48780 <.0001	-0.43701 <.0001	-0.19773 0.0001	0.25570 <.0001	0.20483 <.0001	0.12091 0.0209
wind_avg	-0.10262 0.0501	-0.14774 0.0047	-0.19560 0.0002	-0.13159 0.0119	1.00000	0.06821 0.1935	-0.04944 0.3463	0.19141 0.0002	-0.05256 0.3167	-0.19973 0.0001	-0.06096 0.2453
rain	-0.27346 <.0001	-0.39175 <.0001	0.19469 0.0002	0.48780 <.0001	0.06821 0.1935	1.00000	-0.23066 <.0001	-0.06788 0.1957	0.13508 0.0098	0.08766 0.0945	0.01633 0.7558
pressure_avg	0.08685 0.0976	0.13959 0.0076	-0.75544 <.0001	-0.43701 <.0001	-0.04944 0.3463	-0.23066 <.0001	1.00000	-0.16906 0.0012	-0.59198 <.0001	0.18213 0.0005	-0.06306 0.2295
spring	0.33973 <.0001	0.32905 <.0001	-0.05818 0.2676	-0.19773 0.0001	0.19141 0.0002	-0.06788 0.1957	-0.16906 0.0012	1.00000	-0.33700 <.0001	-0.33455 <.0001	0.01099 0.8342
summer	-0.25936 <.0001	-0.22821 <.0001	0.68548 <.0001	0.25570 <.0001	-0.05256 0.3167	0.13508 0.0098	-0.59198 <.0001	-0.33700 <.0001	1.00000	-0.33455 <.0001	0.01099 0.8342
fall	-0.22956 <.0001	-0.30452 <.0001	0.11315 0.0307	0.20483 <.0001	-0.19973 0.0001	0.08766 0.0945	0.18213 0.0005	-0.33455 <.0001	-0.33455 <.0001	1.00000	0.00100 0.9848
weekend	-0.05444 0.2996	-0.04209 0.4227	0.02231 0.6710	0.12091 0.0209	-0.06096 0.2453	0.01633 0.7558	-0.06306 0.2295	0.01099 0.8342	0.01099 0.8342	0.00100 0.9848	1.00000

2.2.3 회귀모형 비교

회귀모형 비교 결과, 설명변수를 단계적으로 추가할수록 모형 설명력이 개선되었다. PM10 원자료를 종속변수로 사용한 Model 1의 R-Square는 0.1507 이었고, 해면기압을 추가한 Model 2에서는 0.2347로 증가하였다. 여기에 계절 및 주말 정보를 포함한 Model 3에서는 R-Square가 0.3075까지 증가하였다.

log(PM10)을 종속변수로 사용한 모형에서는 설명력이 더 높게 나타났다. 기상요인만 포함한 Model 4의 R-Square는 0.2729였고, 해면기압을 추가한 Model 5에서는 0.3663으로 증가하였다. 최종적으로 해면기압과 계절 및 주말 정보를 모두 포함한 Model 6의 R-Square는 0.4302, 수정 R-Square는 0.4157로 가장 높았다.

Model 6의 결정계수가 0.5를 넘지는 않지만, 이는 미세먼지 농도가 기상 요인만으로 완전히 설명되는 변수가 아니기 때문이다. PM10은 배출원, 장거리 이동 오염물질, 황사, 교통량, 난방, 대기정체 등 다양한 요인의 영향을 받는다. 본 연구는 이러한 모든 요인을 포함한 예측모형이 아니라 수집 가능한 공공데이터를 활용한 설명모형이므로, 수정 R-Square 0.4157은 비교적 낮지만 의미 있는 수준으로 볼 수 있다.

표 6. 회귀모형별 설명력 비교 (Model 1 ~ Model 6까지의 정확한 SAS 회귀 모형 결과는 부록 참조.)

모형	종속변수	설명변수 구성	R-Square	Adj R-Sq	Root MSE
Model 1	PM10	기상요인	0.1507	0.1413	17.3579
Model 2	PM10	기상요인 + 해면기압	0.2347	0.2241	16.5000

Model 3	PM10	기상요인 + 해면기압 + 계절/주말	0.3075	0.2899	15.7845
Model 4	log(PM10)	기상요인	0.2729	0.2648	0.5086
Model 5	log(PM10)	기상요인 + 해면기압	0.3663	0.3574	0.4755
Model 6	log(PM10)	기상요인 + 해면기압 + 계절/주말	0.4302	0.4157	0.4534

2.2.4 최종모형의 회귀계수 해석

최종모형은 Model 6 으로 선택하였다. Model 6 은 log(PM10)을 종속변수로 사용하고 평균기온, 평균습도, 평균풍속, 일강수량, 일평균 해면기압, 계절 정보, 주말 여부를 설명변수로 포함한 모형이다. 이 모형은 비교한 여섯 개 모형 중 가장 높은 수정 R-Square 를 보였고, 잔차 정규성도 가장 양호하였다.

Model 6 에서 평균기온, 평균습도, 평균풍속, 일강수량, 해면기압은 모두 음의 계수를 보였으며 통계적으로 유의하였다. 이는 다른 조건이 일정할 때 해당 기상요인이 증가할수록 log(PM10)이 낮아지는 경향이 있음을 의미한다. 특히 평균풍속의 계수는 -0.30868 로 나타나 대기 확산과 관련된 해석이 가능하다. 풍속이 증가하면 대기 중 입자상 오염물질이 확산되어 PM10 농도가 낮아질 수 있다.

강수량의 계수는 -0.01071 로 나타났으며 유의확률은 <.0001 이었다. 이는 강수량이 증가할수록 PM10 농도가 낮아지는 경향을 의미한다. 비가 오면 대기 중 입자상 물질이 세정되는 효과가 나타날 수 있으므로, 회귀계수의 방향은 환경적 해석과도 부합한다. 평균습도 역시 음의 계수를 보였는데, 이는 습도와 강수 조건, 계절적 대기 상태가 함께 작용한 결과로 해석할 수 있다.

해면기압의 계수는 -0.02021 이며 유의확률은 0.0001 로 나타났다. 단순상관에서는 log(PM10)과 해면기압의 상관계수가 양수였지만, 다중회귀에서는 평균기온, 습도, 강수량, 계절 정보를 통제한 후 음의 계수로 추정되었다. 이는 해면기압이 다른 기상 변수와 밀접하게 관련되어 있기 때문이며, 다중회귀에서는 단순상관보다 조건부 관계를 기준으로 해석해야 한다.

계절 변수 중 봄은 유의한 양의 계수를 보였다. 이는 겨울을 기준으로 했을 때, 다른 기상 조건이 동일하다면 봄철 log(PM10)이 더 높게 나타나는 경향이 있음을 의미한다. 반면 여름과 주말 여부는 통계적으로 유의하지 않았다. 가을 변수는 10% 수준에서는 약한 유의성을 보였지만, 5% 유의수준에서는 뚜렷하다고 보기 어렵다.

표 7. 최종 Model 6 의 회귀계수 추정 결과

변수	추정계수	표준오차	t 값	p-value	표준화계수	VIF
Intercept	25.38295	5.43581	4.67	<.0001	-	0
temp_avg	-0.02562	0.00562	-4.56	<.0001	-0.47257	6.68782
hum_avg	-0.00699	0.00234	-2.98	0.0031	-0.16306	1.86375
wind_avg	-0.30868	0.04130	-7.47	<.0001	-0.33154	1.22566
rain	-0.01071	0.00208	-5.14	<.0001	-0.23947	1.35137
pressure_avg	-0.02021	0.00524	-3.86	0.0001	-0.29320	3.59990
spring	0.31275	0.09753	3.21	0.0015	0.22923	3.18343
summer	0.01867	0.14729	0.13	0.8992	0.01368	7.26053
fall	-0.17549	0.10340	-1.70	0.0905	-0.12816	3.55252
weekend	-0.06453	0.05327	-1.21	0.2266	-0.04917	1.02652

2.3 분석의 타당성 설명

2.3.1 다중공선성 진단

다중회귀모형에서는 설명변수들 사이에 강한 선형관계가 존재할 경우 회귀계수의 표준오차가 커지고, 개별 설명변수의 효과를 안정적으로 해석하기 어려워질 수 있다. 따라서 본 연구에서는 최종모형인 Model 6에 대해 VIF를 이용하여 다중공선성 여부를 확인하였다.

표 7에 의하면, 대부분의 설명변수는 VIF가 5 미만으로 나타났다. 다만 평균기온의 VIF는 6.68782, 여름 변수의 VIF는 7.26053으로 다른 변수들에 비해 다소 높게 나타났다. 이는 평균기온과 계절 변수 사이에 일정한 관련성이 존재하기 때문으로 해석할 수 있다. 실제로 여름철에는 평균기온이 높아지는 경향이 있으므로, 기온 변수와 여름 지시변수 사이에 일부 중복 정보가 존재하는 것은 자연스러운 결과이다.


그러나 모든 설명변수의 VIF가 일반적으로 심각한 다중공선성 기준으로 자주 사용되는 10을 넘지는 않았다. 따라서 본 연구에서는 일부 변수에서 약한 다중공선성 가능성은 인정하되, 회귀계수 해석을 불가능하게 만들 정도의 심각한 다중공선성 문제는 없는 것으로 판단하였다. 또한 계절 변수는 단순히 설명력을 높이기 위한 변수가 아니라 계절에 따른 평균적인 PM10 농도 차이를 통제하기 위한 변수이므로 최종모형에 유지하였다.

2.3.2 잔차분석과 정규성 검토

회귀모형의 타당성을 확인하기 위해 PM10 원자료 모형과 log(PM10) 모형의 Fit Diagnostics 결과를 비교하였다. 그림 4는 Model 3의 PM10 원자료 모형과 Model 6의 log(PM10) 모형에 대한 잔차 진단 결과를 병렬로 제시한 것이다. 두 모형은 모두 평균기온, 평균습도, 평균풍속,

강수량, 해면기압, 계절 및 주말 지시변수를 설명변수로 포함하고 있으므로, 종속변수 변환에 따른 잔차분포의 차이를 비교하기에 적절하다.

그림 4. PM10 원자료 모형(Model 3)과 log(PM10) 모형(Model 6)의 Fit Diagnostics 비교



먼저 PM10 원자료 모형의 Fit Diagnostics 를 보면, 잔차 대 예측값 산점도에서 일부 관측값이 위쪽으로 크게 벗어나는 모습을 확인할 수 있다. 특히 큰 양의 잔차가 존재한다는 것은 실제 PM10 농도가 모형의 예측값보다 훨씬 높게 나타난 고농도 관측일이 있음을 의미한다. 또한 Q-Q plot 에서는 오른쪽 꼬리 부분의 점들이 기준선에서 벗어나며, 잔차 히스토그램에서도 오른쪽으로 긴 꼬리가 관찰된다. 따라서 PM10 원자료 모형은 일부 고농도 관측값의 영향을 크게 받고, 잔차 정규성 측면에서 한계가 있는 것으로 판단된다.

반면 log(PM10) 모형의 Fit Diagnostics 에서는 이러한 문제가 상당히 완화되었다. 잔차 대 예측값 산점도에서 잔차는 대체로 0 을 중심으로 분포하고 있으며, 원자료 모형에서 나타났던 극단적인 양의 잔차가 줄어든 모습을 보인다. 또한 Q-Q plot 에서 대부분의 점들이 기준선에 가깝게 위치하고, 잔차 히스토그램도 원자료 모형보다 대칭적인 형태에 가까워졌다. 이는 로그변환이 PM10 원자료의 오른쪽 꼬리와 일부 고농도 관측값의 영향을 완화하는 데 효과가 있었음을 보여준다.

잔차의 정규성은 주로 Q-Q plot 과 잔차 히스토그램을 통해 시각적으로 검토하였다.

추가적으로 SAS 의 PROC UNIVARIATE 에서 제공되는 Shapiro-Wilk 검정 결과를 보조적으로 참고하였다. PM10 원자료 모형의 Shapiro-Wilk 검정 p-value 는 <0.0001로 나타난 반면, 최종 log(PM10) 모형의 Shapiro-Wilk 검정 p-value 는 0.1894로 나타났다. 이는 원자료 모형에 비해 log(PM10) 모형의 잔차분포가 정규분포에 더 가까워졌다는 시각적 판단과도 일치한다. 또한 log(PM10) 모형에서는 R-Square 가 0.4302, 수정 R-Square 가 0.4157로 나타나 원자료 모형보다 설명력도 개선되었다. (표 6 참조).

종합하면, PM10 원자료 모형은 일부 고농도 관측값으로 인해 잔차분포가 비대칭적이고 Q-Q plot 에서도 기준선에서 벗어나는 모습을 보였다. 반면 log(PM10) 모형은 잔차의 극단성이 완화되고 Q-Q plot 과 히스토그램에서도 정규분포에 더 가까운 형태를 보였다. 따라서 본

연구에서는 단순히 결정계수의 크기뿐만 아니라 잔차분석 결과를 함께 고려하여 $\log(\text{PM}_{10})$ 모형을 최종모형으로 선택하였다.

표 8. 잔차 정규성 검토 결과 요약 (PM₁₀ 원자료 모형-Model 3(좌), $\log(\text{PM}_{10})$ 모형-Model 6(우))

정규성 검토					정규성 검토				
검정	통계량		p 값		검정	통계량		p 값	
Shapiro-Wilk	W	0.89725	Pr < W	<0.0001	Shapiro-Wilk	W	0.994284	Pr < W	0.1894
Kolmogorov-Smirnov	D	0.118062	Pr > D	<0.0100	Kolmogorov-Smirnov	D	0.037765	Pr > D	>0.1500
Cramer-von Mises	W-Sq	1.350692	Pr > W-Sq	<0.0050	Cramer-von Mises	W-Sq	0.077792	Pr > W-Sq	0.2271
Anderson-Darling	A-Sq	7.881348	Pr > A-Sq	<0.0050	Anderson-Darling	A-Sq	0.520464	Pr > A-Sq	0.1934

모형	Q-Q plot 및 히스토그램 판단	Shapiro-Wilk p-value	종합 판단
PM ₁₀ 원자료 모형	오른쪽 꼬리와 기준선 이탈이 뚜렷함	<0.0001	잔차의 정규성 가정 기각
$\log(\text{PM}_{10})$ 모형	기준선에 더 가깝고 분포가 대칭적임	0.1894	잔차의 정규성 가정 기각하지 않음

그림 5. PM₁₀ 원자료 모형(Model 3)과 $\log(\text{PM}_{10})$ 모형(Model 6)의 잔차 대 예측값 산점도 비교 그림





그림 6. PM₁₀ 원자료 모형(Model 3)과 $\log(\text{PM}_{10})$ 모형(Model 6)의 Q-Q plot 비교



2.3.3 이상치와 영향점 검토

본 연구에서는 회귀모형의 타당성을 검토하기 위해 이상치와 영향점 진단을 수행하였다. 이상치는 모형의 예측값과 실제 관측값 사이의 차이가 큰 관측값을 의미하며, 영향점은 특정 관측값이 회귀계수 추정 결과에 큰 영향을 미치는 경우를 의미한다. 본 보고서에서는 스튜던트화 잔차, RStudent, Leverage, COVRATIO, DFFITS, DFBETAS, Cook's Distance를 이용하여 PM10 원자료 모형과 log(PM10) 모형을 비교하였다.

표 9. 이상치 및 영향점 진단 결과 요약

진단지표	판단 기준	기준값	PM10 원자료 모형 기준 초과 개수	log(PM10) 모형 기준 초과 개수	의미
Student Residual	$ Student > 3$	3	6 개	1 개	잔차 크기를 표준화한 이상치 후보
Cook's Distance	$D_i > 1$	1	0 개	0 개	회귀계수 전체에 큰 영향을 주는 영향점
RStudent	$ RStudent > 3$	3	7 개	2 개	해당 관측값을 제외하고 계산한 이상치 후보
Leverage	$h_{ii} > 2p/n$	0.0548	11 개	11 개	레버리지가 큰 관측값 후보
COVRATIO	$1 \pm 3p/n$ 범위 밖	0.9178 미만 또는 1.0822 초과	28 개	21 개	특정 관측값 제거 시 회귀계수 추정값의 정밀도에 영향을 주는 후보
DFFITS	$ DFFITS > 2\sqrt{(p/n)}$	0.3310	18 개	22 개	특정 관측값이 예측값에 미치는 영향
DFBETAS	$ DFBETAS > 2/\sqrt{n}$	0.1047	61 개	86 개	특정 관측값이 개별 회귀계수에 미치는 영향

위 표에서 ($n=365$), ($p=10$)은 절편을 포함한 모수 개수이다. 분석 결과, 스튜던트화 잔차 기준에서는 PM10 원자료 모형에서 6 개, log(PM10) 모형에서 1 개의 이상치 후보가 확인되었다. 이는 로그변환 이후 일부 극단적인 PM10 관측값의 영향이 완화되었음을 보여준다. RStudent 기준에서도 원자료 모형은 7 개, log(PM10) 모형은 2 개로 기준 초과 개수가 감소하였다.

영향점 진단에서는 COVRATIO, DFFITS, DFBETAS 기준에서 일부 후보 관측값이 확인되었다. 다만 DFBETAS는 각 회귀계수별로 계산되는 지표이므로 기준 초과 개수가 많다고 해서 곧바로 모형 전체가 불안정하다고 해석하기는 어렵다. 또한 DFFITS와 COVRATIO는 관측값 수와 모수 개수에 따라 기준값이 작아질 수 있으므로, 후보 관측값을 탐색하는 보조 지표로 해석하였다.

여러 영향점 진단지표 중 Cook' s Distance 는 특정 관측값이 회귀계수 추정 결과 전체에 미치는 영향을 종합적으로 보여주는 지표이다. 본 연구에서는 Cook' s Distance 가 1 을 초과하는지를 기준으로 강한 영향점 여부를 판단하였다. 분석 결과, Cook' s Distance 가 1 을 초과하는 관측값은 PM10 원자료 모형과 log(PM10) 모형 모두에서 확인되지 않았다. 따라서 일부 관측값은 이상치 또는 영향점 후보로 나타났지만, 회귀계수 추정 결과 전체를 크게 왜곡할 정도의 강한 영향점은 없는 것으로 판단하였다.

위의 진단지표 표는 기준 초과 관측값의 개수를 요약한 것이므로, 실제 관측값들이 어떤 형태로 분포하는지는 별도의 산점도를 통해 확인할 필요가 있다. 이에 따라 그림 7 에는 PM10 원자료 모형과 log(PM10) 모형의 레버리지와 스튜던트화 잔차의 관계를 제시하였다.

그림 7. PM10 원자료 모형과 log(PM10) 모형의 레버리지-스튜던트화 잔차 산점도 비교




그림 7 을 보면 PM10 원자료 모형에서는 일부 관측값이 스튜던트화 잔차 기준에서 위쪽으로 크게 벗어나 이상치 후보로 나타난다. 반면 log(PM10) 모형에서는 이러한 극단적인 잔차가 줄어들어, 로그변환 이후 이상치 후보의 영향이 완화되었음을 시각적으로 확인할 수 있다. 또한 일부 관측값은 상대적으로 큰 레버리지를 보이지만, 앞서 Cook' s Distance 기준에서 1 을 초과하는 관측값은 두 모형 모두 확인되지 않았다. 따라서 레버리지가 큰 일부 관측값이 존재하더라도 회귀계수 추정 결과 전체를 크게 왜곡할 정도의 강한 영향점은 없는 것으로 판단하였다.

종합하면, PM10 원자료 모형에서는 일부 고농도 관측값이 이상치 후보로 나타났으나, log(PM10) 모형에서는 이상치 후보가 감소하였다. 또한 Cook' s Distance 기준에서는 두 모형 모두 강한 영향점이 확인되지 않았다. 따라서 log(PM10) 모형은 원자료 모형보다 이상치의 영향을 완화하고 모형의 안정성을 높이는 데 더 적절한 것으로 판단된다.

3. 결론

3.1 분석 결과 요약

본 보고서는 2025년 서울시 일별 PM10 농도와 기상 요인의 관계를 다중회귀분석으로 분석하였다. 분석자료는 서울시 대기질 일별 통계의 PM10 자료, 기상청의 서울(108) 일별 기상자료, 기상청 ASOS 시간자료에서 산출한 일평균 해면기압 자료를 날짜 기준으로 결합하여 구성하였다.

기본모형에서는 평균기온, 평균습도, 평균풍속, 일강수량을 설명변수로 사용하였다. 이후 해면기압을 추가하였고, 계절 및 주말 정보를 0-1 형 설명변수로 변환하여 확장모형에 포함하였다. PM10 원자료와 $\log(\text{PM10})$ 모형을 모두 적합한 결과, $\log(\text{PM10})$ 을 종속변수로 사용한 모형이 원자료 모형보다 더 높은 설명력과 더 양호한 잔차 정규성을 보였다.

최종적으로 선택한 Model 6은 $\log(\text{PM10})$ 을 종속변수로 하고 평균기온, 평균습도, 평균풍속, 일강수량, 해면기압, 계절 정보, 주말 여부를 설명변수로 포함하였다. 이 모형의 R-Square는 0.4302, 수정 R-Square는 0.4157로 나타났다. 평균기온, 평균습도, 평균풍속, 강수량, 해면기압은 모두 음의 계수를 보였고, 봄 변수는 겨울 대비 양의 계수를 보였다.

3.2 분석의 장점 및 한계점

본 분석의 장점은 첫째, 실제 공공데이터를 수집하고 날짜 기준으로 병합하여 회귀분석에 사용할 수 있는 일별 분석자료를 구성했다는 점이다. 둘째, PM10 원자료 모형과 $\log(\text{PM10})$ 모형을 모두 적합하여 종속변수 변환의 효과를 비교하였다. 셋째, 단순히 회귀계수만 해석하지 않고 VIF, 잔차분석, 이상치 및 영향점 진단을 함께 수행하여 회귀모형의 타당성을 검토하였다.

또한 해면기압 자료를 시간 단위 원자료에서 일평균으로 변환하여 기존 일별 자료와 결합한 점도 의미가 있다. 이는 서로 다른 시간 단위의 데이터를 회귀분석에 맞게 정리하는 과정이며, 데이터 전처리의 중요성을 보여준다. 해면기압을 추가한 이후 R-Square와 수정 R-Square가 증가했으므로, 해면기압은 본 자료에서 PM10 농도 변동을 설명하는 데 일정 부분 기여한 것으로 판단된다.

한계점도 존재한다. 첫째, 본 연구는 기상 요인 중심의 분석이므로 PM10 농도에 영향을 주는 배출원 정보를 충분히 포함하지 못했다. 교통량, 산업활동, 난방 사용, 황사 여부,

장거리 이동 오염물질, 대기정체 지표 등이 누락되어 있다. 둘째, 일별 자료는 시간 순서를 갖기 때문에 자기상관 가능성이 존재하지만, 본 연구의 분석 범위를 고려하여 전날 PM10이나 시계열 모형을 사용하지 않았다. 셋째, 계절 변수와 평균기온 사이에서 일부 다중공선성 가능성이 존재한다.

따라서 본 연구의 회귀계수는 엄밀한 인과효과라기보다는 관측자료에서 나타난 조건부 선형관계로 해석해야 한다. 예를 들어 해면기압이 음의 계수를 보였다고 해서 해면기압 자체가 직접적으로 PM10을 낮춘다고 단정할 수는 없다. 이는 다른 기상요인과 계절 정보를 통제된 상태에서 나타난 통계적 관련성으로 이해하는 것이 적절하다.

3.3 추가 연구사항 제안

본 연구는 다중선형회귀모형을 중심으로 2025년 서울시 일별 PM10 농도와 기상 요인의 관계를 분석하였다. 그러나 PM10 농도는 기상 조건뿐만 아니라 황사, 장거리 이동 오염물질, 교통량, 난방 수요, 산업활동, 전날 대기질 상태 등 다양한 요인의 영향을 받을 수 있다. 따라서 본 연구의 모형을 확장하기 위해서는 다음과 같은 추가 연구가 가능하다.

첫째, 황사 발생 여부나 고농도 미세먼지 주의보 발령 여부를 설명변수로 포함할 수 있다. 본 연구에서 일부 고농도 관측일은 평균기온, 평균습도, 평균풍속, 강수량, 해면기압과 같은 일반적인 기상요인만으로 충분히 설명되지 않았다. 특히 PM10 농도는 국내 배출원뿐만 아니라 황사나 국외 유입 오염물질의 영향을 받을 수 있으므로, 이러한 사건성 변수를 추가하면 고농도 미세먼지 발생일에 대한 설명력이 개선될 가능성이 있다.

둘째, 교통량, 유동인구, 난방 수요, 산업활동 지표 등 배출원 관련 변수를 추가할 수 있다. 미세먼지는 기상 조건과 배출량이 함께 작용하여 결정되므로, 기상자료만으로는 설명력이 제한될 수밖에 없다. 예를 들어 겨울철 난방 수요, 출퇴근 교통량, 산업활동량과 같은 변수는 PM10 농도의 변동을 설명하는 데 추가적인 정보를 제공할 수 있다.

셋째, 향후 보다 확장된 분석에서는 전날 PM10 농도, 이동평균, 자기상관 구조 등을 고려한 시계열 회귀모형을 검토할 수 있다. 본 연구의 최종모형인 $\log(\text{PM10})$ 모형은 평균기온, 평균습도, 평균풍속, 강수량, 해면기압, 계절 및 주말 정보를 포함하였으며 수정 결정계수는 0.4157로 나타났다. 추가적으로 전날 $\log(\text{PM10})$ 을 설명변수로 포함한 보조모형을 적합한 결과, 수정 결정계수는 0.6394로 상승하였다. 또한 전날 $\log(\text{PM10})$ 의 회귀계수는 통계적으로 유의하게 나타나, 일별 PM10 농도가 당일 기상조건뿐만 아니라 전날의 대기질 상태와도

밀접하게 관련될 수 있음을 보여준다. 다만 전날 $\log(\text{PM}_{10})$ 을 포함한 이후 평균습도와 해면기압의 회귀계수는 통계적으로 유의하지 않게 나타났다. 이는 전날의 대기질 상태가 포함되면서, 기존 모형에서 기상요인이 설명하던 변동의 일부가 전날 PM_{10} 변수에 의해 설명되었을 가능성을 시사한다. 그러나 전날 PM_{10} 을 포함하는 모형은 시차변수를 사용하는 모형이므로, 일반적인 다중회귀분석을 넘어 시계열 회귀분석의 성격을 가진다. 따라서 본 보고서에서는 이를 최종모형으로 채택하지 않고, 향후 연구에서 검토할 수 있는 확장 방향으로 제시하였다.

표 10. 로그변환을 한 기존 회귀모형(Model 6)과 전날 종속변수를 설명변수로 추가한 회귀모형 비교

Model 6: 해면기압, 계절 및 주말 지시변수를 포함한 log(PM10) 회귀모형

The REG Procedure
Model: MODEL1
Dependent Variable: log_pm10

Number of Observations Read365

Number of Observations Used365

Analysis of Variance

Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	9	55.10310	6.12257	29.78	<.0001
Error	355	72.96823	0.20560		
Corrected Total	364	128.09133			

Root MSE0.45343

R-Square0.4302

Dependent Mean3.29654

Adj R-Sq0.4157

Coeff Var13.75479

Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Standardized Estimate	Variance Inflation
Intercept	1	25.38295	5.43581	4.67	<.0001	0	0
temp_avg	1	-0.02562	0.00562	-4.56	<.0001	-0.47257	6.68782
hum_avg	1	-0.00699	0.00234	-2.98	0.0031	-0.16306	1.86375
wind_avg	1	-0.30968	0.04130	-7.47	<.0001	-0.33154	1.22566
rain	1	-0.01071	0.00208	-5.14	<.0001	-0.23947	1.35137
pressure_avg	1	-0.02021	0.00524	-3.86	0.0001	-0.29320	3.59990
spring	1	0.31275	0.09753	3.21	0.0015	0.22923	3.18343
summer	1	0.01967	0.14729	0.13	0.8992	0.01368	7.26053
fall	1	-0.17549	0.10340	-1.70	0.0905	-0.12816	3.55252
weekend	1	-0.06453	0.05327	-1.21	0.2266	-0.04917	1.02652

Model 8: 전날 log(PM10)을 포함한 log(PM10) 보조 회귀모형

The REG Procedure
Model: MODEL1
Dependent Variable: log_pm10

Number of Observations Read365

Number of Observations Used364

Number of Observations with Missing Values1

Analysis of Variance

Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	10	83.05895	8.30590	65.36	<.0001
Error	353	44.85798	0.12708		
Corrected Total	363	127.91694			

Root MSE0.35648

R-Square0.6493

Dependent Mean3.29539

Adj R-Sq0.6394

Coeff Var10.81746

Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Standardized Estimate	Variance Inflation
Intercept	1	7.91059	4.43193	1.78	0.0751	0	0
log_pm10_lag1	1	0.57907	0.03694	14.87	<.0001	0.57932	1.52782
temp_avg	1	-0.01056	0.00453	-2.33	0.0203	-0.19464	7.02001
hum_avg	1	0.00066329	0.00191	0.35	0.7291	0.01549	2.01009
wind_avg	1	-0.21449	0.03308	-6.48	<.0001	-0.23051	1.27217
rain	1	-0.01040	0.00164	-6.34	<.0001	-0.23247	1.35138
pressure_avg	1	-0.00581	0.00423	-1.37	0.1708	-0.08424	3.79270
spring	1	0.18453	0.07734	2.39	0.0176	0.13528	3.23578
summer	1	0.03755	0.11597	0.32	0.7463	0.02753	7.27595
fall	1	-0.07703	0.08173	-0.94	0.3466	-0.05626	3.58718
weekend	1	-0.04795	0.04192	-1.14	0.2535	-0.03654	1.02732

마지막으로 서울시 전체 평균이 아니라 자치구별 또는 측정소별 자료를 이용하면 공간적 차이를 함께 분석할 수 있다. 본 연구는 서울시 전체의 일별 평균 PM_{10} 농도를 사용하였기 때문에 서울 내부의 지역별 차이를 반영하지 못한다. 향후 연구에서는 자치구별 또는 측정소별 PM_{10} 자료를 이용하여 지역별 고정효과나 측정소별 특성을 포함한 회귀모형을 구성할 수 있다. 이를 통해 도시 내부의 미세먼지 변동 요인을 더 세밀하게 파악할 수 있을 것이다.

참고문헌

기후에너지환경부. 「대기오염도현황」. 2025 년 1 월- 6 월 미세먼지(PM10) 월별 · 도시별

대기오염도 자료. 검색일: 2026 년 6 월 3 일.

https://kosis.kr/statHtml/statHtml.do?orgId=106&tblId=DT_106N_03_0200045&conn_path=I

2

서울특별시 대기환경정보. 「서울시 대기질 일별 통계」. 2025 년 1 월-12 월 미세먼지 PM10

일별 자료. 검색일: 2026 년 5 월 27 일.

<https://cleanair.seoul.go.kr/statistics/dayAverage>

기상청 기상자료개방포털. 「서울(108) 기온, 강수량, 습도, 바람 분석 일자료」. 2025 년

1 월-12 월 서울지점 일별 기상자료. 검색일: 2026 년 5 월 27 일.

<https://data.kma.go.kr/climate/RankState/selectRankStatisticsDivisionList.do>

서울특별시 대기환경정보. 「대기오염물질: 미세먼지(PM10)」. 검색일: 2026 년 5 월 27 일.

<https://cleanair.seoul.go.kr/information/info12#about>

기상청 기상자료개방포털. 「종관기상관측(ASOS) 시간자료」. 서울(108) 지점 2025 년 1 월

1 일 00 시-2025 년 12 월 31 일 23 시 해면기압 자료. 검색일: 2026 년 5 월 28 일.

<https://data.kma.go.kr/data/grnd/selectAsosRltmList.do?pgmNo=36>

서울특별시 도시교통실. 「2025 년 서울특별시 교통량 조사결과」. 서울특별시

교통정보시스템(TOPIS) 자료실. 검색일: 2026 년 6 월 3 일.

https://topis.seoul.go.kr/refRoom/openRefRoom_2.do

국립환경과학원. 「교통량 통제에 따라 미세먼지 및 유해물질 농도 낮아져」.

기후에너지환경부 보도자료. 등록일: 2018 년 7 월 13 일. 검색일: 2026 년 6 월 3 일.

<https://mcee.go.kr/home/web/board/read.do?boardId=883630>

김영일, 이권호. 「미세먼지 농도 예측을 위한 머신러닝 기법의 정확도 분석」.

『한국대기환경학회지』, 제 39 권 제 2 호, 2023, pp.149-164.

<https://doi.org/10.5572/KOSAE.2023.39.2.149>

부록. SAS 프로그램 코드 및 주요 결과표

부록 1. 분석에 사용한 SAS 코드

/* 1. 데이터 불러오기 */

```
proc import datafile="/home/RA_final_ver3.csv"
  out=air_raw
  dbms=csv
  replace;
  guessingrows=max;
  getnames=yes;
run;
```

/* 2. 원본 데이터 구조 확인 */

```
proc contents data=air_raw;
run;
```

```
proc print data=air_raw(obs=10);
run;
```

/* 3. 분석용 데이터셋 생성 */

```
data air;
  set air_raw;

  /* 원본 변수명을 분석용 변수명으로 정리 */
  pm10      = 'pm10( $\mu\text{g}/\text{m}^3$ )'n;
  temp_avg  = 'temp_avg( $^{\circ}\text{C}$ )'n;
  rain      = 'rain(mm)'n;
  hum_avg   = 'hum_avg(%rh)'n;
  pressure_avg = 'pressure_avg(hPa)'n;

  /* 강수량 결측값 처리: 비가 오지 않은 날로 보고
  0으로 대체 */
  if rain = . then rain = 0;

  /* 날짜 변수 정리 */
  date_sas = date;
  format date_sas yymmdd10.;

  /* log(PM10) 생성 */
  if pm10 > 0 then log_pm10 = log(pm10);

  /* 월 변수 생성 */
  month = month(date_sas);

  /* 계절 지시변수 생성: 겨울을 기준범주로 설정
  */
  spring = (month in (3, 4, 5));
  summer = (month in (6, 7, 8));
  fall   = (month in (9, 10, 11));

  /* 주말 지시변수 생성: 평일을 기준범주로 설정
  */
```

```
    if weekday(date_sas) in (1, 7) then weekend = 1;
    else weekend = 0;
run;
```

/* 4. 분석용 데이터 확인 */

```
proc contents data=air;
run;

proc print data=air(obs=10);
  var date_sas pm10 log_pm10 temp_avg hum_avg
  wind_avg rain pressure_avg
  spring summer fall weekend;
run;
```

/* 5. 기초통계량 */

```
proc means data=air n mean std min q1 median q3 max;
  var pm10 log_pm10 temp_avg hum_avg wind_avg
  rain pressure_avg
  spring summer fall weekend;
  title "기초통계량";
run;
```

/* 6. 상관분석 */

```
proc corr data=air pearson;
  var pm10 log_pm10 temp_avg hum_avg wind_avg
  rain pressure_avg
  spring summer fall weekend;
  title "상관분석";
run;
```

/* 7. PM10 원자료와 log(PM10) 분포 확인 */

```
proc sgplot data=air;
  histogram pm10;
  density pm10;
  title "PM10 원자료 분포";
run;
```

```
proc sgplot data=air;
  histogram log_pm10;
  density log_pm10;
  title "log(PM10) 분포";
run;
```

/* 8. Model 1: 기상요인만 포함한 PM10 원자료 모형 */

```
proc reg data=air;
  model pm10 = temp_avg hum_avg wind_avg rain /
  vif stb;
  title "Model 1: 기상요인만 포함한 PM10 원자료
  회귀모형";
```

```

run;
quit;

/* 9. Model 2: 기상요인과 해면기압을 포함한 PM10
원자료 모형 */
proc reg data=air;
    model pm10 = temp_avg hum_avg wind_avg rain
pressure_avg / vif stb;
    title "Model 2: 해면기압을 추가한 PM10 원자료
회귀모형";
run;
quit;

/* 10. Model 3: 해면기압, 계절 및 주말 지시변수를
포함한 PM10 원자료 모형 */
proc reg data=air;
    model pm10 = temp_avg hum_avg wind_avg rain
pressure_avg
                spring summer fall weekend / vif
stb r influence;
    output out=reg_pm10
        p=pred_pm10
        r=resid_pm10
        student=student_pm10
        cookd=cookd_pm10
        h=leverage_pm10;
    title "Model 3: 해면기압, 계절 및 주말
지시변수를 포함한 PM10 원자료 회귀모형";
run;
quit;

/* 11. Model 4: 기상요인만 포함한 log(PM10) 모형 */
proc reg data=air;
    model log_pm10 = temp_avg hum_avg wind_avg rain
/ vif stb;
    title "Model 4: 기상요인만 포함한 log(PM10)
회귀모형";
run;
quit;

/* 12. Model 5: 기상요인과 해면기압을 포함한
log(PM10) 모형 */
proc reg data=air;
    model log_pm10 = temp_avg hum_avg wind_avg rain
pressure_avg / vif stb;
    title "Model 5: 해면기압을 추가한 log(PM10)
회귀모형";
run;
quit;

/* 13. Model 6: 해면기압, 계절 및 주말 지시변수를
포함한 log(PM10) 최종모형 */
proc reg data=air;
    model log_pm10 = temp_avg hum_avg wind_avg rain
pressure_avg
                spring summer fall weekend /
vif stb r influence;

```

```

output out=reg_log
        p=pred_log
        r=resid_log
        student=student_log
        cookd=cookd_log
        h=leverage_log;
    title "Model 6: 해면기압, 계절 및 주말
지시변수를 포함한 log(PM10) 회귀모형";
run;
quit;

/* 14. PM10 원자료 모형 잔차 진단 */
proc sgplot data=reg_pm10;
    scatter x=pred_pm10 y=resid_pm10;
    refline 0 / axis=y;
    title "잔차 대 예측값 산점도: PM10 원자료 모형";
run;

proc univariate data=reg_pm10 normal;
    var resid_pm10;
    histogram resid_pm10 / normal;
    qqplot resid_pm10 / normal(mu=est sigma=est);
    title "잔차 정규성 검토: PM10 원자료 모형";
run;

/* 15. log(PM10) 모형 잔차 진단 */
proc sgplot data=reg_log;
    scatter x=pred_log y=resid_log;
    refline 0 / axis=y;
    title "잔차 대 예측값 산점도: log(PM10) 모형";
run;

proc univariate data=reg_log normal;
    var resid_log;
    histogram resid_log / normal;
    qqplot resid_log / normal(mu=est sigma=est);
    title "잔차 정규성 검토: log(PM10) 모형";
run;

/* 16. 스튜던트화 잔차 기준 이상치 후보 확인 */
proc print data=reg_pm10;
    where abs(student_pm10) > 3;
    var date_sas pm10 pred_pm10 resid_pm10
student_pm10 cookd_pm10 leverage_pm10;
    title "PM10 원자료 모형: 스튜던트화 잔차 기준
이상치 후보";
run;

proc print data=reg_log;
    where abs(student_log) > 3;
    var date_sas pm10 log_pm10 pred_log resid_log
student_log cookd_log leverage_log;
    title "log(PM10) 모형: 스튜던트화 잔차 기준
이상치 후보";
run;

/* 17. Cook's Distance 기준 영향점 후보 확인 */

```

```

proc print data=reg_pm10;
  where cookd_pm10 > 1;
  var date_sas pm10 pred_pm10 resid_pm10 student_pm10 cookd_pm10 leverage_pm10;
  title "PM10 원자료 모형: Cook's Distance > 1 기준 영향점 후보";
run;

proc print data=reg_log;
  where cookd_log > 1;
  var date_sas pm10 log_pm10 pred_log resid_log student_log cookd_log leverage_log;
  title "log(PM10) 모형: Cook's Distance > 1 기준 영향점 후보";
run;

/* 18. 레버리지와 스튜던트화 잔차 산점도 */
proc sgplot data=reg_pm10;
  scatter x=leverage_pm10 y=student_pm10;
  refline 0 / axis=y;
  title "레버리지와 스튜던트화 잔차 산점도: PM10 원자료 모형";
run;

proc sgplot data=reg_log;
  scatter x=leverage_log y=student_log;
  refline 0 / axis=y;
  title "레버리지와 스튜던트화 잔차 산점도: log(PM10) 모형";
run;

```

부록 2. Model 1 ~ Model 6 까지의 SAS 회귀모형 결과

Model 1: 기상요인만 포함한 PM10 원자료 회귀모형

The REG Procedure
Model: MODEL1
Dependent Variable: pm10

Number of Observations Read	365
Number of Observations Used	365

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	4	19248	4812.02248	15.97	<.0001
Error	360	108467	301.29636		
Corrected Total	364	127715			

Root MSE	17.35789	R-Square	0.1507
Dependent Mean	31.82466	Adj R-Sq	0.1413
Coeff Var	54.54227		

Parameter Estimates						
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Variance Inflation
Intercept	1	57.17935	6.51294	8.78	<.0001	0
temp_avg	1	-0.39539	0.09313	-4.25	<.0001	1.25447
hum_avg	1	-0.12928	0.08231	-1.57	0.1171	1.56780
wind_avg	1	-4.37027	1.47538	-2.96	0.0033	1.06752
rain	1	-0.24265	0.07954	-3.05	0.0025	1.34376

Model 2: 해면기압을 추가한 PM10 원자료 회귀모형

The REG Procedure
Model: MODEL1
Dependent Variable: pm10

Number of Observations Read	365
Number of Observations Used	365

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	5	29978	5995.53341	22.02	<.0001
Error	359	97737	272.24822		
Corrected Total	364	127715			

Root MSE	16.49995	R-Square	0.2347
Dependent Mean	31.82466	Adj R-Sq	0.2241
Coeff Var	51.84642		

Parameter Estimates							
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Standardized Estimate	Variance Inflation
Intercept	1	1131.82408	171.29314	6.61	<.0001	0	0
temp_avg	1	-0.99254	0.12994	-7.64	<.0001	-0.57975	2.70259
hum_avg	1	-0.22729	0.07978	-2.85	0.0046	-0.16794	1.63023
wind_avg	1	-7.34911	1.48055	-4.96	<.0001	-0.24997	1.18973
rain	1	-0.24230	0.07561	-3.20	0.0015	-0.17151	1.34376
pressure_avg	1	-1.03700	0.16518	-6.28	<.0001	-0.47643	2.70184

Model 3: 해면기압, 계절 및 주말 지시변수를 포함한 PM10 원자료 회귀모형

The REG Procedure
Model: MODEL1
Dependent Variable: pm10

Number of Observations Read	365
Number of Observations Used	365

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	9	39266	4362.93153	17.51	<.0001
Error	355	88448	249.15041		
Corrected Total	364	127715			

Root MSE	15.78450	R-Square	0.3075
Dependent Mean	31.82466	Adj R-Sq	0.2899
Coeff Var	49.59833		

Parameter Estimates						
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Variance Inflation
Intercept	1	743.52804	189.22702	3.93	0.0001	0
temp_avg	1	-0.66990	0.19555	-3.43	0.0007	6.68782
hum_avg	1	-0.09688	0.08161	-1.19	0.2360	1.86375
wind_avg	1	-7.83897	1.43759	-5.45	<.0001	1.22566
rain	1	-0.24527	0.07254	-3.38	0.0008	1.35137
pressure_avg	1	-0.66537	0.18240	-3.65	0.0003	3.59990
spring	1	9.22481	3.39508	2.72	0.0069	3.18343
summer	1	-4.78382	5.12727	-0.93	0.3514	7.26053
fall	1	-5.12043	3.59956	-1.42	0.1558	3.55252
weekend	1	-2.93249	1.85449	-1.58	0.1147	1.02652

Model 4: 기상요인만 포함한 log(PM10) 회귀모형

The REG Procedure
Model: MODEL1
Dependent Variable: log_pm10

Number of Observations Read	365
Number of Observations Used	365

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	4	34.95525	8.73881	33.78	<.0001
Error	360	93.13608	0.25871		
Corrected Total	364	128.09133			

Root MSE	0.50864	R-Square	0.2729
Dependent Mean	3.29654	Adj R-Sq	0.2648
Coeff Var	15.42941		

Parameter Estimates							
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Standardized Estimate	Variance Inflation
Intercept	1	4.51436	0.19085	23.65	<.0001	0	0
temp_avg	1	-0.01256	0.00273	-4.60	<.0001	-0.23170	1.25447
hum_avg	1	-0.00841	0.00241	-3.49	0.0005	-0.19622	1.56780
wind_avg	1	-0.18673	0.04323	-4.37	<.0001	-0.20271	1.06752
rain	1	-0.01061	0.00233	-4.55	<.0001	-0.23710	1.34376

Model 5: 해면기압을 추가한 log(PM10) 회귀모형

The REG Procedure
Model: MODEL1
Dependent Variable: log_pm10

Number of Observations Read	365
Number of Observations Used	365

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	5	46.91635	9.38327	41.50	<.0001
Error	359	81.17498	0.22611		
Corrected Total	364	128.09133			

Root MSE	0.47551	R-Square	0.3663
Dependent Mean	3.29654	Adj R-Sq	0.3574
Coeff Var	14.42466		

Parameter Estimates						
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Variance Inflation
Intercept	1	40.39492	4.93652	8.18	<.0001	0
temp_avg	1	-0.03250	0.00374	-8.68	<.0001	2.70259
hum_avg	1	-0.01168	0.00230	-5.08	<.0001	1.63023
wind_avg	1	-0.28819	0.04267	-6.75	<.0001	1.18973
rain	1	-0.01060	0.00218	-4.86	<.0001	1.34376
pressure_avg	1	-0.03482	0.00476	-7.27	<.0001	2.70184

Model 6: 해면기압, 계절 및 주말 지시변수를 포함한 log(PM10) 회귀모형

The REG Procedure
Model: MODEL1
Dependent Variable: log_pm10

Number of Observations Read	365
Number of Observations Used	365

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	9	65.10310	6.12257	29.78	<.0001
Error	355	72.98823	0.20560		
Corrected Total	364	128.09133			

Root MSE	0.45343	R-Square	0.4302
Dependent Mean	3.29654	Adj R-Sq	0.4157
Coeff Var	13.75479		

Parameter Estimates							
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t	Standardized Estimate	Variance Inflation
Intercept	1	25.38295	5.43581	4.67	<.0001	0	0
temp_avg	1	-0.02562	0.00562	-4.56	<.0001	-0.47257	6.68782
hum_avg	1	-0.00699	0.00234	-2.98	0.0031	-0.16306	1.86375
wind_avg	1	-0.30868	0.04130	-7.47	<.0001	-0.33154	1.22566
rain	1	-0.01071	0.00208	-5.14	<.0001	-0.23947	1.35137
pressure_avg	1	-0.03021	0.00524	-3.86	0.0001	-0.29320	3.59990
spring	1	0.91275	0.09753	3.21	0.0015	0.23223	3.18343
summer	1	0.01867	0.14729	0.13	0.8992	0.01368	7.26053
fall	1	-0.17549	0.10340	-1.70	0.0905	-0.12816	3.55252
weekend	1	-0.06453	0.05327	-1.21	0.2286	-0.04917	1.02652